FINAL PROJECT REPORT DATA ANALYTICS

Sri Mulyani – 2802534071

1. [LO-3 – 20 Poin] Review & Evaluasi Kualitas Data

a. Summarize the main data quality issues identified during Mid Project

Dataset yang digunakan dalam proyek ini adalah *Customer Shopping Behaviour Dataset* dari Kaggle yang terdiri dari 3.900 baris data yang merepresentasikan informasi demografis, perilaku pembelian, dan penilaian pelanggan. Setelah dilakukan pemeriksaan awal pada tahap UTS, dataset ini dinyatakan tidak mengandung *missing value*, baris duplikat, maupun nilai *outlier* berdasarkan metode Interquartile Range (IQR) yang digunakan pada tahap UTS. Hasil tersebut juga dikonfirmasi kembali pada tahap pasca-UTS. Meskipun demikian, ditemukan satu permasalahan kualitas yang cukup krusial, yaitu inkonsistensi label pada kolom *Frequency of Purchases*. Secara spesifik, kategori "*Quarterly*" dan "*Every 3 Months*" memiliki makna yang sepenuhnya identik, begitu pula pasangan "*Bi-weekly*" dan "*Fortnightly*". Apabila inkonsistensi ini tidak ditangani, distribusi frekuensi pembelian akan tampak memiliki enam kategori yang berbeda, padahal secara semantik hanya terdapat empat kelompok yang benar-benar unik. Hal ini berpotensi mendistorsi hasil agregasi, visualisasi, maupun segmentasi yang bergantung pada kolom tersebut.

b. Evaluate how effectiveness your data wrangling process was in improving data quality.

Penanganan inkonsistensi dilakukan dengan menggabungkan label yang bermakna sama, yaitu *Bi-weekly* dilebur ke dalam *Fortnightly*, dan *Every 3 Months* dilebur ke dalam *Quarterly*. Efektivitas penanganan ini dapat dikonfirmasi secara visual melalui distribusi kolom *Frequency of Purchases* sebelum dan sesudah *wrangling*, di mana proporsi antar kategori tetap konsisten tanpa pergeseran yang berarti. Hal ini membuktikan bahwa proses penggabungan label tidak menimbulkan distorsi baru pada data.

Selain penanganan inkonsistensi, dilakukan *encoding* terhadap variabel biner *Subscription Status*, *Discount Applied*, dan *Promo Code Used* dari format teks "Yes/No" ke nilai numerik 1 dan 0, sebagai prasyarat untuk tahap pemodelan. Pada tahap pasca-UTS, dilakukan pengecekan ulang secara menyeluruh yang mencakup validasi *missing value*, duplikasi, *outlier*, konsistensi tipe data, dan nilai yang tidak sesuai logika bisnis, seperti usia di bawah 15 tahun atau nilai *purchase amount* negatif. Hasil pengecekan ini mengkonfirmasi bahwa dataset dalam kondisi bersih dan tidak terdapat permasalahan tambahan di luar yang telah ditangani sebelumnya.

Sebagai pelengkap untuk keperluan analisis yang lebih mendalam, dilakukan pula *feature engineering* dengan membuat empat variabel turunan, yaitu *Age Group* (pengelompokan usia menjadi *Young Adult*, *Adult*, dan *Senior*), *Purchase Frequency Tier* (pengelompokan frekuensi belanja menjadi *Low*, *Medium*, dan *High*), *Loyalty Level* (empat kuantil berdasarkan *Previous Purchases*), dan *Customer Segment* (klasifikasi *High Spender* dan *Regular Spender* berdasarkan persentil ke-75). Perlu ditekankan bahwa keempat variabel ini merupakan hasil transformasi analitik, bukan perbaikan atas masalah kualitas data, sehingga tidak menambah jumlah observasi maupun mengubah nilai asli dataset.

c. Support your evaluation using appropriate indicators (e.g., reduction in missing values, improved consistency, reduced outliers).

Untuk memberikan gambaran yang lebih terukur, berikut adalah ringkasan perbandingan kondisi dataset sebelum dan sesudah proses *data wrangling* berdasarkan indikator-indikator yang relevan.

Indikator Kualitas	Sebelum Wrangling	Sesudah Wrangling	Keterangan
Missing value	0	0	Dikonfirmasi ulang pasca-UTS

Baris duplikat	0	0	Dikonfirmasi ulang pasca-UTS
Outlier	0	0	Dikonfirmasi ulang pasca-UTS
Label ganda di Frequency of Purchases	6 label (4 unik)	4 label bersih	Inkonsistensi diselesaikan
Format variabel biner	Teks (Yes/No)	Numerik (1/0)	Siap untuk pemodelan
Fitur turunan untuk analisis	Tidak ada	4 variabel baru	Feature engineering

Tabel 1. Perbandingan Indikator Kualitas Data Sebelum dan Sesudah Wrangling

Secara keseluruhan, proses *data wrangling* yang dilakukan dinilai efektif karena berhasil menyelesaikan satu-satunya permasalahan kualitas yang ditemukan tanpa mengorbankan integritas data asli. Dataset akhir yang digunakan dalam seluruh tahap analisis berikutnya berdiri di atas fondasi yang bersih, konsisten, dan valid, kondisi yang menjadi prasyarat penting bagi ketepatan dan kepercayaan *insight* bisnis yang dihasilkan.

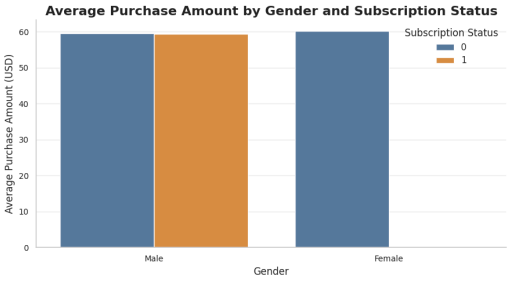
2. [LO-2 – 30 Poin] Advanced Pattern, Trend, and Relationship Analysis

a. Extend your exploratory analysis by examining deeper or more specific relationships between variables (e.g., segmented analysis, time-based trends, subgroup comparison).

Eksplorasi data dilakukan secara multidimensi mencakup analisis demografis, perilaku, pola pengeluaran, kategori produk, serta hubungan antar variabel. Setiap temuan yang diperoleh tidak hanya diinterpretasikan secara deskriptif, tetapi juga dihubungkan dengan implikasinya terhadap pemahaman perilaku pelanggan dan pengambilan keputusan bisnis.

2.1 Analisis Demografis

a. Gender dan Subscription Status

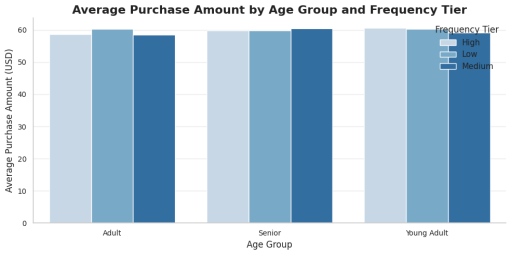


Analisis hubungan antara *Gender* dan *Subscription Status* mengungkap pola yang mencolok pada dataset yang digunakan. Dari 3.900 pelanggan, seluruh pelanggan yang berstatus *subscriber* berasal dari segmen *Male*, sedangkan tidak ditemukan pelanggan *Female* yang berstatus *subscriber*. Hubungan ini terkonfirmasi secara statistik melalui uji *Chi-Square* dengan *Cramér's V* = 0,42, yang tergolong kekuatan hubungan yang cukup besar. Namun perlu dicatat bahwa pola ekstrem ini kemungkinan merupakan artefak dataset sintetis daripada representasi kondisi bisnis nyata, sehingga interpretasi perlu dilakukan dengan sangat hati-hati.

Meskipun demikian, temuan ini tetap bermakna secara analitis karena mengidentifikasi kesenjangan konversi yang sangat besar antara dua segmen demografis utama. Mengingat segmen *Female*

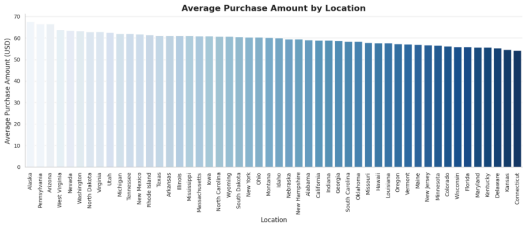
memiliki jumlah pelanggan yang relatif besar namun belum tercatat sebagai *subscriber*, segmen ini dapat dipertimbangkan sebagai kandidat untuk dievaluasi lebih lanjut dalam strategi akuisisi pelanggan, dengan catatan bahwa validasi terhadap data transaksi aktual tetap diperlukan sebelum kesimpulan ini dijadikan dasar kebijakan bisnis.

b. Kelompok Usia dan Frekuensi Pembelian



Analisis kombinasi *Age Group* dan *Purchase Frequency Tier* menunjukkan bahwa variasi rata-rata *purchase amount* antar kelompok berada pada rentang yang sangat sempit, yaitu sekitar $58 hingga $61. Tidak ada kelompok usia tertentu yang secara konsisten mengeluarkan nilai transaksi yang jauh berbeda dari kelompok lainnya. Temuan ini menunjukkan bahwa usia dan intensitas pembelian bukanlah variabel yang cukup untuk memprediksi besarnya nilai transaksi seorang pelanggan. Strategi pemasaran yang terlalu berfokus pada segmentasi usia saja, tanpa mempertimbangkan variabel lain, kemungkinan tidak akan menghasilkan perbedaan pendapatan yang signifikan.

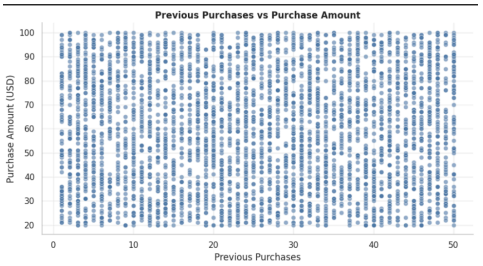
c. Variasi Geografis



Analisis berbasis lokasi menunjukkan rentang rata-rata *purchase amount* yang cukup bervariasi, yaitu antara $54 hingga $68 di antara seluruh wilayah. Lima lokasi dengan nilai transaksi tertinggi adalah Alaska ($67,60), Pennsylvania ($66,57), Arizona ($66,55), West Virginia ($63,88), dan Nevada ($63,38). Perbedaan antar wilayah ini, apabila divalidasi dengan data transaksi nyata, dapat mengindikasikan perbedaan preferensi atau daya beli regional. Perusahaan dapat memanfaatkan hasil ini sebagai dasar untuk merancang kampanye pemasaran yang disesuaikan secara geografis, khususnya dengan mengalokasikan sumber daya promosi secara lebih besar pada wilayah-wilayah dengan potensi *purchase amount* tertinggi.

2.2 Analisis Perilaku Pelanggan

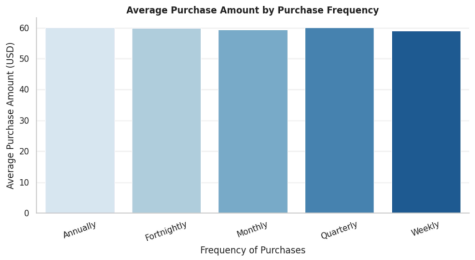
a. Riwayat Pembelian dan Nilai Transaksi



Visualisasi *scatter plot* antara *Previous Purchases* (rentang 1 hingga 50 transaksi) dan *Purchase Amount* menunjukkan sebaran titik yang merata di seluruh rentang nilai $20 hingga $100 tanpa konsentrasi kuat di tingkat riwayat pembelian tertentu. Dengan kata lain, pelanggan dengan riwayat

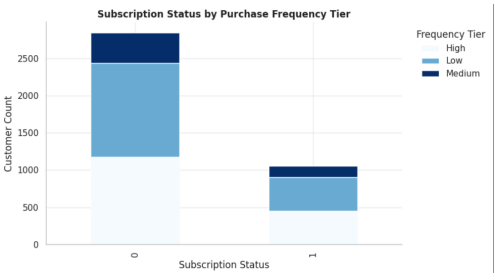
pembelian yang panjang tidak terbukti memiliki nilai transaksi yang lebih besar dibandingkan pelanggan baru. Temuan ini memiliki implikasi penting: program loyalitas yang dirancang dengan asumsi bahwa pelanggan lama otomatis akan berbelanja lebih banyak perlu ditinjau ulang, karena data tidak mendukung asumsi tersebut.

b. Frekuensi Pembelian dan Pengeluaran



Analisis rata-rata *purchase amount* berdasarkan *Frequency of Purchases* menghasilkan temuan yang serupa. Seluruh kategori frekuensi, mulai dari *Weekly* ($58,97) hingga *Annually* ($60,17), memiliki rata-rata yang hampir identik dengan selisih kurang dari $1,50. Pola ini menunjukkan bahwa seberapa sering seorang pelanggan berbelanja tidak berkorelasi dengan seberapa besar yang mereka keluarkan dalam satu transaksi. Hal ini penting karena menunjukkan bahwa intensitas pembelian dan nilai transaksi adalah dua dimensi perilaku yang perlu dikelola secara terpisah dalam strategi pemasaran.

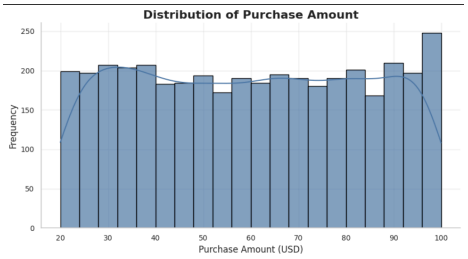
c. Status Berlangganan dan Intensitas Pembelian



Analisis silang antara *Subscription Status* dan *Purchase Frequency Tier* menunjukkan bahwa distribusi tier pembelian antara kelompok *subscriber* dan *non-subscriber* bersifat proporsional, dimana keduanya didominasi oleh tier *Low* dan *High*, dengan tier *Medium* paling sedikit di kedua kelompok. Kondisi ini mengimplikasikan bahwa status berlangganan tidak otomatis mencerminkan intensitas pembelian yang lebih tinggi. Artinya, *subscriber* tidak selalu berbelanja lebih sering dari *non-subscriber*, yang mengindikasikan bahwa nilai program berlangganan bagi pelanggan mungkin lebih bersifat akses atau eksklusivitas, bukan peningkatan frekuensi belanja.

2.3 Pola Pengeluaran (Spending Patterns)

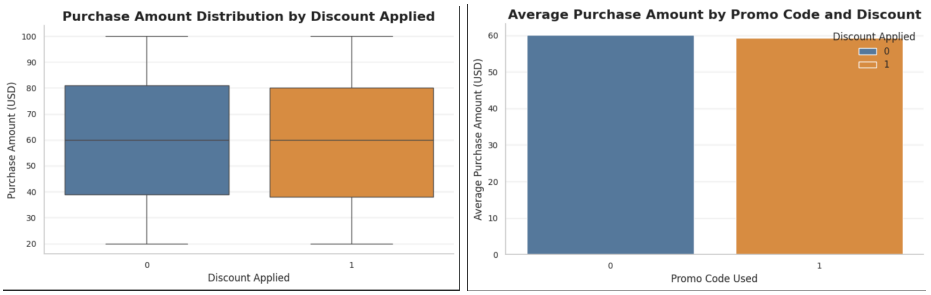
a. Distribusi Purchase Amount



Distribusi *Purchase Amount* bersifat hampir seragam (*uniform*) di rentang $20 hingga $100, dengan frekuensi per bin yang relatif stabil di kisaran 170 hingga 210 transaksi. Satu-satunya pengecualian terdapat pada rentang $95 hingga $100 yang menunjukkan lonjakan frekuensi mendekati 250

transaksi, mengindikasikan adanya kecenderungan sebagian pelanggan untuk melakukan pembelian mendekati batas nilai tertinggi. Distribusi yang merata ini bermakna karena menunjukkan bahwa basis pelanggan tersegmentasi cukup merata di berbagai tingkat pengeluaran, sehingga strategi pemasaran yang terlalu berfokus pada satu segmen pengeluaran saja berpotensi melewatkan kelompok pelanggan lainnya.

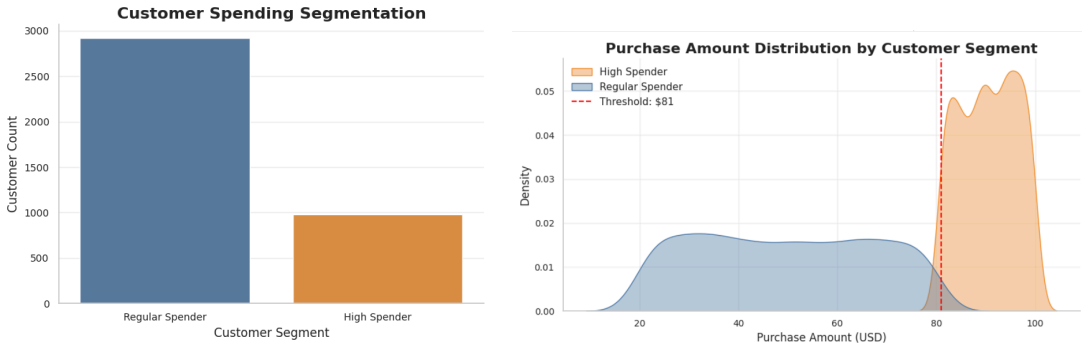
b. Efektivitas Diskon dan Promo Code



Sebelum menginterpretasikan temuan pada bagian ini, perlu dicatat bahwa *Discount Applied* dan *Promo Code Used* memiliki korelasi yang hampir sempurna (*Cramér's V* = 0,9995), mengindikasikan bahwa kedua variabel ini tidak independen dalam dataset yang digunakan, kemungkinan karena keduanya di-*generate* dari mekanisme yang sama, sehingga analisis keduanya secara terpisah tidak dapat menghasilkan *insight* yang berbeda.

Dengan mempertimbangkan keterbatasan tersebut, temuan yang dapat dicatat adalah tidak ditemukannya perbedaan *purchase amount* yang berarti antara pelanggan yang memperoleh diskon dan yang tidak. Pelanggan yang mendapat diskon memiliki rata-rata $59,28, sedangkan yang tidak mendapat diskon rata-rata $60,13, dengan selisih kurang dari $1 dan median identik di $60 untuk kedua kelompok. Pola yang sama terlihat pada penggunaan *promo code*, di mana nilai transaksi antara pengguna dan non-pengguna sama-sama berada di kisaran $60. Temuan ini mengindikasikan bahwa program promosi pada dataset ini tidak terbukti mendorong peningkatan nilai transaksi, sehingga perusahaan dapat mengevaluasi kembali apakah tujuan program promosi sebaiknya lebih diarahkan pada peningkatan frekuensi pembelian atau tujuan bisnis lainnya yang belum diukur dalam analisis ini.

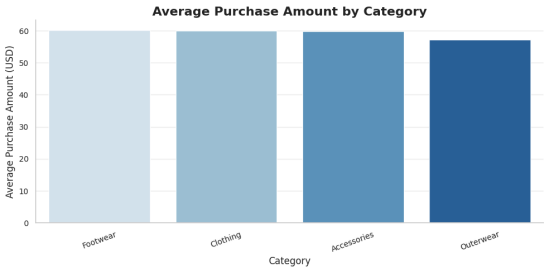
c. Segmentasi High Spender dan Regular Spender



Segmentasi berbasis persentil ke-75 dari *Purchase Amount* ($81) menghasilkan dua kelompok yang berbeda secara mencolok: *High Spender* dengan rata-rata $90,55 (n = 978, atau 25,1% dari total pelanggan) dan *Regular Spender* dengan rata-rata $49,46 (n = 2.922, atau 74,9% dari total pelanggan). Meskipun jumlah *High Spender* lebih sedikit, kontribusi nilai transaksi mereka jauh lebih besar per individunya. Perbedaan ini terkonfirmasi secara statistik dengan efek yang sangat besar (Cohen's d = 3,12) dan konsisten di berbagai *threshold* (Q60 hingga Q85), yang akan dibahas lebih mendalam pada bagian evaluasi metode analitik.

2.4 Tren Kategori Produk dan Musim

a. Spending per Kategori

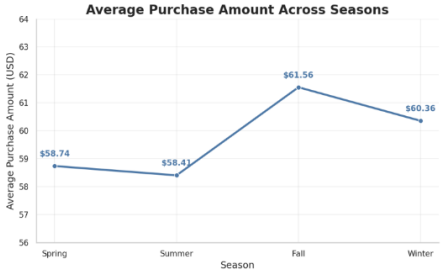


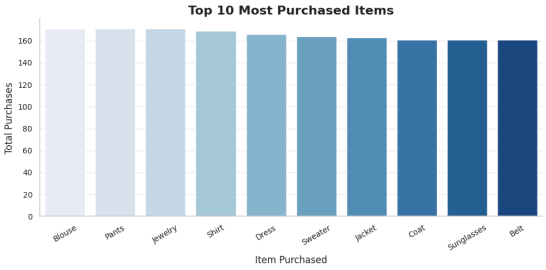
Di antara empat kategori produk, *Footwear* memiliki rata-rata *purchase amount* tertinggi ($60,26), diikuti *Clothing* ($60,03), *Accessories* ($59,84), dan *Outerwear* ($57,17). Yang paling menonjol adalah *Outerwear* yang secara konsisten memiliki nilai terendah di semua kombinasi musim dan *frequency tier*, dengan nilai terendah pada kombinasi *Outerwear–Medium* sebesar $54,90. Hasil ini bermakna karena mengindikasikan bahwa *Outerwear* mungkin memiliki kisaran harga yang lebih rendah di dataset ini, atau pelanggan cenderung lebih selektif dalam membelinya, sehingga perlu strategi penetapan harga atau bundling yang berbeda dibanding kategori lain.

Untuk menguji apakah efek musim terhadap *purchase amount* berbeda antar kategori produk, dilakukan analisis segmentasi silang antara *Season* dan *Category*. Hasil analisis menunjukkan beberapa pola yang menarik. *Outerwear* secara konsisten mencatat nilai *purchase amount* terendah di seluruh musim termasuk *Winter*, yang secara intuitif seharusnya menjadi musim dengan permintaan tertinggi untuk kategori tersebut. Sebaliknya, *Footwear* mempertahankan posisi tertinggi di hampir semua kombinasi musim. Pola ini mengindikasikan bahwa variasi nilai transaksi antar kategori lebih dipengaruhi oleh karakteristik kategori produk itu sendiri daripada faktor musiman.

Temuan ini diperkuat oleh hasil uji *Chi-Square* yang menunjukkan tidak adanya hubungan yang signifikan antara *Season* dan *Category* (p = 0,541), mengkonfirmasi bahwa preferensi kategori produk pada dataset ini tidak berubah secara berarti antar musim. Dalam konteks bisnis, apabila hal ini divalidasi dengan data transaksi nyata, implikasinya adalah bahwa strategi promosi musiman yang terlalu berfokus pada kategori tertentu, misalnya mendorong *Outerwear* di musim *Winter*, belum tentu menghasilkan perubahan pola pembelian yang signifikan tanpa didukung oleh strategi penetapan harga atau bundling yang lebih mendasar.

b. Tren Musiman





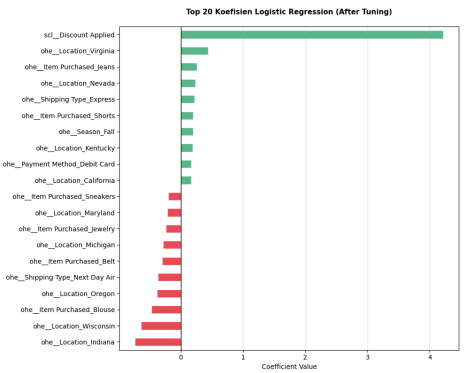
Analisis tren musiman menunjukkan bahwa musim *Fall* mencatat rata-rata *purchase amount* tertinggi ($61,56), diikuti *Winter* ($60,36), *Spring* ($58,74), dan *Summer* ($58,41). Meskipun perbedaan nilai antar musim relatif kecil, pola ini menunjukkan bahwa rata-rata *purchase amount* pada dataset cenderung lebih tinggi pada musim *Fall* dan *Winter*. Meskipun demikian, interpretasi terhadap pola tersebut perlu dilakukan secara hati-hati karena dataset tidak menyediakan informasi waktu aktual sehingga hubungan dengan pola musiman di dunia nyata tidak dapat dipastikan. Dari sisi volume, item terpopuler berdasarkan jumlah transaksi adalah *Blouse*, *Pants*, dan *Jewelry* yang

masing-masing mencatat 171 transaksi, dengan selisih antar item yang sangat kecil, mengindikasikan preferensi yang cukup merata di antara produk-produk tersebut.

b. Identify the most influential variables related to the problem context.

Berdasarkan analisis *feature importance* pada model *Logistic Regression*, *Discount Applied* merupakan variabel yang memberikan kontribusi terbesar dalam memprediksi *Subscription Status* dibandingkan fitur lainnya pada dataset yang digunakan. Selanjutnya, variabel *Location* dan *Item Purchased* juga menunjukkan kontribusi terhadap prediksi, meskipun nilainya jauh lebih kecil dibandingkan *Discount Applied*. Sementara itu, hasil *correlation matrix* menunjukkan bahwa *Discount Applied* dan *Promo Code Used* memiliki korelasi yang sangat kuat (Pearson r = 1,00), sedangkan kedua variabel tersebut memiliki korelasi sebesar 0,70 terhadap *Subscription Status*. Sebaliknya, hampir seluruh variabel memiliki korelasi yang sangat rendah terhadap *Purchase Amount*, dengan korelasi tertinggi hanya dimiliki oleh *Review Rating* (r = 0,03) dan *Previous Purchases* (r = 0,01). Analisis ini menunjukkan bahwa variabel yang paling berpengaruh dalam konteks permasalahan bisnis adalah variabel yang berkaitan dengan program promosi dan status *subscription*, bukan variabel yang secara langsung berkorelasi dengan besarnya nilai transaksi.

Meskipun demikian, hasil tersebut perlu diinterpretasikan secara hati-hati karena dataset yang digunakan bersifat sintetis, sehingga hubungan antarvariabel kemungkinan dihasilkan secara artifisial dan belum tentu mencerminkan mekanisme kausal pada kondisi bisnis nyata. Selain itu, hubungan yang hampir sempurna antara *Discount Applied* dan *Promo Code Used* (Pearson r = 1,00; Cramér's V = 0,9995) mengindikasikan adanya potensi multikolinearitas, sehingga kedua variabel kemungkinan merepresentasikan informasi yang hampir sama. Oleh karena itu, interpretasi *feature importance* difokuskan pada *Discount Applied* sebagai representasi utama pengaruh program promosi, sedangkan kontribusi *Promo Code Used* tidak dibahas secara terpisah agar tidak memberikan kesan bahwa keduanya merupakan faktor independen. Dengan mempertimbangkan keterbatasan tersebut, temuan ini tetap bernilai sebagai identifikasi pola prediktif awal dan dapat dijadikan hipotesis yang perlu divalidasi menggunakan data transaksi aktual sebelum diterapkan sebagai dasar pengambilan keputusan bisnis.



Dari visualisasi koefisien tersebut, terlihat bahwa *Discount Applied* memiliki nilai koefisien terbesar dibandingkan fitur lainnya. Hal ini konsisten dengan hasil *feature importance* sebelumnya yang menunjukkan bahwa variabel promosi merupakan prediktor utama *Subscription Status*, sedangkan *Location* dan *Item Purchased* hanya memberikan kontribusi yang relatif kecil.

c. Explain why these relationships are meaningful using analytical evidence.

Hubungan antar variabel tersebut menjadi bermakna karena didukung oleh beberapa bukti analitis yang saling melengkapi. Korelasi yang sangat kuat antara *Discount Applied* dan *Promo Code Used* (r = 1,00), serta korelasi sebesar 0,70 terhadap *Subscription Status,* menunjukkan adanya hubungan yang kuat antara penggunaan diskon dan status subscription pada dataset yang dianalisis. Namun, hubungan tersebut tidak dapat diinterpretasikan sebagai hubungan sebab-akibat maupun hubungan jangka panjang. Di sisi lain, meskipun hampir seluruh variabel memiliki korelasi bivariat yang

mendekati nol terhadap *Purchase Amount,* model *Logistic Regression* tetap mencapai akurasi sebesar 86,41% dalam memprediksi *Subscription Status*. Hasil ini menunjukkan bahwa kemampuan prediksi model berasal dari kombinasi beberapa variabel secara simultan, bukan dari hubungan linear satu variabel terhadap target. Oleh karena itu, analisis *correlation matrix* dan *feature importance* saling melengkapi dalam menjelaskan pola yang relevan terhadap permasalahan bisnis, yaitu bahwa karakteristik promosi memiliki peran yang lebih besar dalam memprediksi status subscription dibandingkan variabel perilaku transaksi secara individual.

Hasil ini merupakan salah satu *counter-intuitive finding* yang paling berarti dalam analisis ini. Bertentangan dengan asumsi umum bahwa pelanggan yang berlangganan cenderung lebih aktif berbelanja karena merasa mendapatkan nilai lebih dari program berlangganan, analisis silang antara *Subscription Status* dan *Purchase Frequency Tier* justru menunjukkan distribusi yang proporsional antara kedua kelompok. Subscriber dan non-subscriber sama-sama didominasi oleh tier *Low* dan *High*, dengan tier *Medium* paling sedikit di kedua kelompok, tanpa perbedaan pola yang berarti.

Temuan ini diperkuat secara statistik oleh hasil uji *Chi-Square* yang menunjukkan tidak adanya hubungan signifikan antara *Purchase Frequency Tier* dan *Subscription Status* ($p = 0{,}725$), mengkonfirmasi bahwa perbedaan distribusi antar kelompok tidak melebihi yang dapat dijelaskan oleh kebetulan semata. Implikasinya cukup mendasar: apabila nilai program berlangganan tidak tercermin dalam peningkatan frekuensi belanja, maka motivasi pelanggan untuk berlangganan kemungkinan lebih bersifat akses eksklusif atau manfaat non-transaksional lainnya yang tidak terukur dalam dataset ini. Perusahaan perlu mempertimbangkan apakah program berlangganan yang ada saat ini sudah dikomunikasikan dengan proposisi nilai yang jelas kepada pelanggan, atau justru perlu dirancang ulang agar manfaatnya lebih terasa secara langsung dalam perilaku pembelian.

3. [LO-3 – 20 Poin] Evaluation of Analytical Methods and Metrics

a. Describe the analytical techniques or models used in your project (e.g., correlation analysis, statistical comparison, simple predictive or scoring approach if applicable).

Tahap evaluasi dilakukan untuk memvalidasi apakah pola dan *insight* yang diperoleh selama proses *Exploratory Data Analysis* (EDA) memiliki dasar statistik yang kuat sehingga dapat digunakan sebagai dasar pengambilan keputusan bisnis. Sebelum menentukan metode analisis, dilakukan uji normalitas menggunakan Shapiro-Wilk terhadap variabel *Purchase Amount*. Karena hasil pengujian menunjukkan bahwa data tidak mengikuti distribusi normal, analisis inferensial pada penelitian ini lebih mengutamakan metode non-parametrik yang tidak bergantung pada asumsi normalitas.

- ***Correlation Analysis*** **(Pearson and Spearman Correlation)**

  Analisis korelasi digunakan untuk mengevaluasi hubungan antara variabel numerik dengan *Purchase Amount*. Dua pendekatan diterapkan secara bersamaan, yaitu *Pearson Correlation* untuk mengukur hubungan linear dan *Spearman Rank Correlation* untuk mengukur hubungan monotonik yang lebih sesuai untuk data non-normal. Penggunaan kedua metode ini bertujuan untuk memperoleh hasil yang lebih komprehensif mengenai pola hubungan antar variabel numerik sebelum dilakukan pemodelan *machine learning*.

- **Chi-Square Test of Independence and Cramér's V**

  Untuk menganalisis hubungan antar variabel kategorikal digunakan *Chi-Square Test*. Uji ini bertujuan mengetahui apakah dua variabel kategorikal saling berasosiasi secara statistik. Agar hubungan yang ditemukan tidak hanya signifikan secara statistik tetapi juga dapat diukur kekuatannya, analisis dilengkapi dengan *Cramér's V* sebagai ukuran *effect size*. Teknik ini digunakan untuk mengidentifikasi variabel-variabel kategorikal yang memiliki

hubungan kuat sehingga dapat menjadi pertimbangan dalam interpretasi bisnis maupun proses pemodelan.

- **Kruskal-Wallis Test and ANOVA**

  Perbandingan *Purchase Amount* pada beberapa kelompok pelanggan dilakukan menggunakan *Kruskal-Wallis Test* sebagai metode utama karena data tidak memenuhi asumsi normalitas. Sebagai pembanding, dilakukan pula *One-Way ANOVA* untuk melihat konsistensi hasil apabila menggunakan pendekatan parametrik. Kombinasi kedua metode ini memberikan validasi bahwa kesimpulan yang diperoleh tidak bergantung pada satu jenis pengujian statistik saja.

- **A/B Testing using the Mann-Whitney U Test**

  Untuk memvalidasi segmentasi pelanggan berdasarkan tingkat pengeluaran, dilakukan *A/B Testing* dengan membandingkan kelompok *High Spender* dan *Regular Spender* menggunakan *Mann-Whitney U Test*. Pengujian ini bertujuan memastikan bahwa kedua kelompok memang memiliki perbedaan perilaku pembelian yang signifikan sehingga segmentasi yang dibangun memiliki dasar statistik yang kuat. Selain itu, dilakukan *robustness check* menggunakan beberapa nilai *threshold* segmentasi untuk memastikan bahwa hasil yang diperoleh tetap konsisten dan tidak bergantung pada satu batas pemisah tertentu.

- ***Machine Learning* Classification Models**

  Selain analisis statistik, penelitian ini juga menerapkan pendekatan *machine learning* untuk memprediksi *Subscription Status* pelanggan. Empat algoritma klasifikasi dibandingkan, yaitu *Logistic Regression*, *Support Vector Machine* (SVM), *Random Forest*, dan *XGBoost*. Karena distribusi kelas pada *dataset* tidak seimbang, penanganan *class imbalance* dilakukan menggunakan *Synthetic Minority Oversampling Technique* (SMOTE) yang diintegrasikan ke dalam *ImbPipeline*, sehingga proses *oversampling* hanya diterapkan pada data latih di setiap *fold cross-validation* dan tidak menyebabkan *data leakage*.

  Seluruh model dievaluasi menggunakan *Stratified 10-Fold Cross Validation* agar proporsi kelas tetap terjaga pada setiap *fold*. Model dengan performa terbaik pada tahap *baseline* kemudian dioptimalkan menggunakan *RandomizedSearchCV* untuk memperoleh kombinasi *hyperparameter* yang lebih optimal. Pendekatan ini memungkinkan evaluasi dilakukan secara lebih objektif sekaligus memastikan bahwa model yang dipilih memiliki kemampuan *generalisasi* yang baik terhadap data baru.

b. Select and explain appropriate performance or evaluation metrics used to assess the effectiveness of your analysis (e.g., strength of correlation, error measures, distribution comparison, robustness checks).

Efektivitas setiap teknik analisis dievaluasi menggunakan metrik yang sesuai dengan karakteristik metode yang diterapkan. Karena distribusi data tidak normal berdasarkan uji Shapiro-Wilk, interpretasi hasil inferensial terutama mengacu pada metode non-parametrik.

3.1 *Evaluation Metrics for Correlation Analysis*

Pada analisis korelasi digunakan koefisien *Pearson* (r) dan *Spearman* (ρ) untuk mengukur kekuatan hubungan antara variabel numerik dengan *Purchase Amount*. Nilai *p-value* digunakan untuk menentukan apakah hubungan tersebut signifikan secara statistik. Hasil menunjukkan bahwa seluruh variabel numerik memiliki nilai $p > 0{,}05$ sehingga tidak ditemukan hubungan linear maupun monotonik yang signifikan. Korelasi tertinggi diperoleh pada *Review Rating* (Pearson $r = 0{,}03$; $p = 0{,}055$), namun masih belum memenuhi tingkat signifikansi yang ditetapkan.

3.2 *Evaluation Metrics for Categorical Association*

	Pair	Chi-Square	p-value	df	Cramér's V (Effect Size)	Significant (p<0.05)
0	Gender × Subscription Status	676.7944	0.0000	1	0.4166	True
1	Discount Applied × Promo Code Used	3895.9211	0.0000	1	0.9995	True
2	Season × Category	7.9337	0.5408	9	0.0260	False
3	Subscription Status × Purchase Frequency Tier	0.6434	0.7249	2	0.0128	False

Hubungan antar variabel kategorikal dievaluasi menggunakan uji Chi-Square, sedangkan kekuatan hubungan diukur menggunakan Cramér's V. Terdapat tiga temuan utama yang perlu disorot. Pertama, *Gender* dan *Subscription Status* terbukti memiliki hubungan yang signifikan dengan kekuatan yang cukup besar (Cramér's V = 0,42), yang menjadi dasar rekomendasi kampanye akuisisi *subscriber* berbasis gender. Kedua, *Discount Applied* dan *Promo Code Used* memiliki hubungan yang hampir sempurna (Cramér's V = 0,9995), mengkonfirmasi bahwa keduanya berperilaku sebagai satu variabel dalam praktik bisnis dan sebaiknya diperlakukan demikian dalam pemodelan untuk menghindari multikolinearitas. Ketiga, tidak ditemukan hubungan yang signifikan antara *Season* dan *Category* (p = 0,541), maupun antara *Purchase Frequency Tier* dan *Subscription Status* (p = 0,725), temuan yang mengurangi asumsi umum bahwa pelanggan yang berlangganan pasti berbelanja lebih sering.

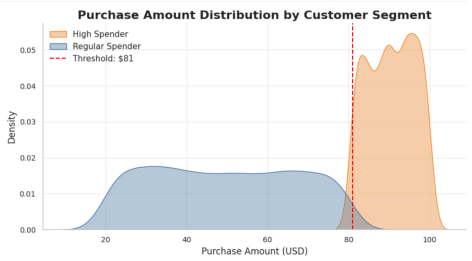
3.3 *Evaluation Metrics for Group Comparison*

	Grouping Variable	ANOVA F-stat	ANOVA p-value	Kruskal-Wallis H	Kruskal p-value	Eta-Squared (η^2)	Significant
0	Gender	0.7690	0.3806	0.7987	0.3715	0.0002	False
1	Category	1.4536	0.2252	4.4112	0.2203	0.0011	False
2	Season	3.7461	0.0106	11.3785	0.0098	0.0029	True
3	Subscription Status	0.1908	0.6623	0.1867	0.6657	0.0000	False
4	Discount Applied	1.2352	0.2665	1.2652	0.2607	0.0003	False

Perbedaan *Purchase Amount* antar kelompok dievaluasi menggunakan *Kruskal-Wallis Test* dengan *p-value* sebagai indikator signifikansi statistik dan *Eta-Squared* (η^2) sebagai ukuran efek. Karena data tidak berdistribusi normal, uji Kruskal-Wallis digunakan sebagai acuan utama untuk menguji perbedaan *Purchase Amount* antar kelompok, dengan uji ANOVA disertakan sebagai pembanding. Dari seluruh variabel yang diuji yaitu *Gender*, *Category*, *Season*, *Subscription Status*, dan *Discount Applied*, hanya *Season* yang menghasilkan perbedaan *Purchase Amount* yang signifikan secara statistik (Kruskal-Wallis p = 0,01). Namun, ukuran efeknya sangat kecil dengan nilai *Eta-Squared* (η^2) = 0,0029, yang berarti musim hanya menjelaskan 0,29% dari total variasi *purchase amount*. Hasil ini penting untuk disampaikan secara jujur: signifikansi statistik dan signifikansi praktis adalah dua hal yang berbeda. Dalam kasus ini, meskipun perbedaan antar musim dapat terdeteksi secara statistik, dampaknya terlalu kecil untuk menjadi dasar kebijakan bisnis yang signifikan.

3.4 *Evaluation Metrics for A/B Testing*

Efektivitas segmentasi *High Spender* dan *Regular Spender* dievaluasi menggunakan *Mann-Whitney U Test*. Nilai statistik *U* dan *p-value* digunakan untuk menguji signifikansi perbedaan kedua kelompok, sedangkan *Cohen's d* digunakan untuk mengukur besarnya efek.



Komponen	Keterangan
Group A (Control)	Regular Spender : Purchase Amount < $81 (n = 2.922, 74,9%)
Group B (Treatment)	High Spender : Purchase Amount ≥ $81 (n = 978, 25,1%)
Metrik yang diuji	Purchase Amount (USD)
Metode statistik	Mann-Whitney U Test (non-parametrik)
Tingkat signifikansi	$\alpha = 0{,}05$
Hasil uji	$U = 2.857.716$, $p < 0{,}0001 \rightarrow H_0$ ditolak
Effect size	Cohen's d = 3,12 (efek sangat besar)
Robustness check	Threshold Q60–Q85: Cohen's d 2,85–3,45, semua $p < 0{,}0001$

Tabel 2. Ringkasan Desain dan Hasil A/B Testing Segmentasi Pelanggan

Hasil A/B testing mengkonfirmasi bahwa perbedaan *purchase amount* antara kedua kelompok sangat signifikan secara statistik ($p < 0{,}0001$) sekaligus bermakna secara praktis (Cohen's d = 3,12, jauh melampaui ambang efek besar di 0,80). Yang lebih penting, hasil ini terbukti *robust* karena konsisten di berbagai pilihan *threshold* dari Q60 hingga Q85, artinya kesimpulan tidak bergantung pada satu titik batas tertentu. Dengan fondasi statistik ini, segmentasi *High Spender* dan *Regular Spender* dapat diandalkan sebagai dasar perancangan program yang berbeda untuk kedua kelompok.

3.5 *Machine Learning Model Evaluation Metrics*

Performa model klasifikasi dievaluasi menggunakan beberapa metrik, yaitu *Accuracy*, *Precision*, *Recall*, *F1-Score*, *AUC-ROC*, *Cross Validation Accuracy*, *Cross Validation F1-Macro*, *Cross Validation Standard Deviation*, serta *Generalization Gap*. *Accuracy* mengukur ketepatan prediksi secara keseluruhan, sedangkan *Precision*, *Recall*, dan *F1-Score* mengevaluasi kemampuan model dalam mengidentifikasi pelanggan yang berlangganan. *AUC-ROC* digunakan untuk menilai kemampuan model membedakan kedua kelas pada berbagai nilai ambang keputusan. Selain itu, *Cross Validation* dan *Generalization Gap* digunakan untuk mengevaluasi konsistensi performa model terhadap data baru serta mendeteksi potensi *overfitting*.

Berdasarkan metrik evaluasi tersebut, Logistic Regression memberikan performa terbaik dibandingkan model lainnya. Ringkasan hasil sebelum dan sesudah *hyperparameter tuning* ditunjukkan pada Tabel 3.

No.	Metrik	Before Tuning	After Tuning	Delta
1	Accuracy	86,54%	86,41%	- 0,13%
2	F1-Macro	84,96%	84,83%	- 0,13%
3	F1-Subscriber	80,08%	79,92%	- 0,16%
4	Precision	66,77%	66,56%	- 0,21%
5	Recall-Subscriber	100,00%	100,00%	= 0,00%
6	AUC-ROC	90,70%	91,40%	+0,70%
7	CV Accuracy	83,30%	83,43%	+0,13%

8	CV F1-Macro	81,66%	81,87%	+0,21%
9	CV Std	±1,88%	±1,94%	+0,06%
10	Generalization Gap	3,24%	2,98%	- 0,26%

Tabel 3. Perbandingan Hasil Metrik Evaluasi Before vs After Tuning – Logistic Regression

Hasil tuning menghasilkan *trade-off* yang secara keseluruhan menguntungkan. Beberapa metrik pada data uji mengalami penurunan yang sangat tipis, yaitu *Accuracy* turun 0,13% dan F1-Macro turun 0,13%. Namun penurunan minor ini diimbangi oleh peningkatan yang lebih bermakna pada kemampuan generalisasi model: AUC-ROC meningkat dari 90,70% menjadi 91,40% (+0,70%), CV F1-Macro naik dari 81,66% menjadi 81,87%, dan *Generalization Gap* menyempit dari 3,24% menjadi 2,98%. Nilai *Recall-Subscriber* tetap stabil di 100,00%, yang berarti model tidak melewatkan satu pun dari 211 calon *subscriber* pada data uji.

Pemilihan *Logistic Regression* sebagai model final didasarkan bukan semata pada nilai F1-Macro, melainkan pada kombinasi tiga keunggulan utama: kemampuan mendeteksi seluruh calon *subscriber* tanpa terkecuali (*Recall* 100%), kualitas pemisahan kelas terbaik (AUC-ROC 91,40%), dan ketahanan terhadap *overfitting* yang paling konsisten (*Generalization Gap* 2,98% dengan CV Std ±1,94%). Bahkan dibandingkan model *ensemble* yang lebih kompleks seperti *Random Forest* (Recall-Sub 87,68%) dan *XGBoost* (Recall-Sub 74,41%), *Logistic Regression* unggul secara signifikan dalam kemampuannya mendeteksi kelas minoritas. Hal ini menunjukkan bahwa pola hubungan antara fitur-fitur yang digunakan dan *Subscription Status* dapat ditangkap secara efektif oleh model *Logistic Regression*, sehingga penggunaan model yang lebih kompleks belum memberikan peningkatan performa yang berarti. Dengan demikian, Logistic Regression sudah mampu menangkap pola pada dataset secara efektif.

c. Discuss the limitations of your analysis or models based on these metrics.

Terdapat tiga keterbatasan utama yang perlu dicatat. Pertama, nilai *Precision* sebesar 66,56% berarti sekitar satu dari tiga prediksi *subscriber* adalah *false positive*. Ini merupakan konsekuensi yang disengaja dari prioritas memaksimalkan *Recall*, namun implikasinya dalam konteks bisnis adalah sekitar sepertiga anggaran promosi yang diarahkan berdasarkan prediksi model berpotensi terbuang pada pelanggan yang sebenarnya tidak akan berlangganan. Keterbatasan ini dapat dimitigasi dengan menyesuaikan *threshold* prediksi sesuai rasio biaya bisnis yang berlaku.

Kedua, dataset bersifat statis tanpa informasi *timestamp*. Tanpa dimensi waktu, model hanya merepresentasikan satu *snapshot* perilaku pelanggan dan tidak dapat menangkap perubahan tren dari waktu ke waktu. Akibatnya, model perlu di-*retrain* secara berkala apabila diterapkan dalam sistem yang dinamis.

Ketiga, penggunaan *Ordinal Encoding* pada kolom nominal *Item Purchased* (25 nilai unik) dan *Location* (50 nilai unik) secara implisit mengimplikasikan urutan yang tidak ada dalam data aslinya. *One-Hot Encoding* lebih tepat secara metodologi, namun dengan 75 nilai unik gabungan pada dataset ~3.900 baris, risiko *curse of dimensionality* menjadi pertimbangan yang tidak dapat diabaikan. *Trade-off* ini dipilih secara sadar dengan kesadaran atas konsekuensi metodologisnya.

4. [LO-4– 30 Points] Exploratory Data Analysis (EDA)

a. Propose 1–2 actionable recommendations based on your insights.

Berdasarkan keseluruhan temuan dari proses *Exploratory Data Analysis* dan evaluasi statistik yang telah dilakukan, berikut dua rekomendasi bisnis yang dapat dipertimbangkan oleh perusahaan.

Rekomendasi 1: Peningkatan Jumlah Subscriber Melalui Kampanye Bertarget Berbasis Gender

- **Justifikasi Analitik**

  Dasar analitik rekomendasi ini bertumpu pada dua temuan yang saling melengkapi. Pertama, uji Chi-Square menunjukkan bahwa hubungan antara gender dan Subscription Status bersifat signifikan secara statistik dengan kekuatan asosiasi yang cukup besar (Cramér's V = 0,417, p < 0,0001). Kedua, ketika temuan ini ditelusuri lebih jauh ke tingkat distribusi aktual, ditemukan bahwa seluruh 1.248 pelanggan perempuan dalam dataset berstatus non-subscriber, sementara 39,7% dari 2.652 pelanggan laki-laki telah berstatus subscriber. Kesenjangan ini menunjukkan bahwa segmen perempuan merepresentasikan potensi pertumbuhan subscriber yang hingga saat ini sepenuhnya belum terkonversi.

  Penemuan ini semakin diperkuat oleh analisis feature importance model Logistic Regression yang menempatkan Discount Applied sebagai prediktor terkuat Subscription Status dengan koefisien positif yang jauh melampaui fitur lainnya, serta korelasi 0,70 antara penggunaan diskon dan status berlangganan. Kedua temuan ini secara bersama-sama membentuk landasan yang cukup kuat: segmen dengan konversi nol dipadukan dengan instrumen yang terbukti paling efektif mendorong konversi, yaitu diskon.

- **Langkah Implementasi**

  Perusahaan dapat merancang kampanye akuisisi subscriber yang secara eksplisit menyasar segmen perempuan dengan pesan, insentif, dan saluran komunikasi yang disesuaikan. Sebagai titik masuk, program trial subscription dengan diskon dapat difokuskan pada kategori produk yang paling relevan bagi segmen ini berdasarkan data, Accessories dan Clothing merupakan kategori dengan frekuensi pembelian tertinggi di kalangan pelanggan perempuan, sehingga insentif yang dikaitkan dengan kategori ini berpotensi lebih relevan dan menarik bagi mereka.

  Pada tahap operasional, model Logistic Regression yang telah dibangun dapat diintegrasikan ke dalam sistem Customer Relationship Management (CRM) untuk memprioritaskan pelanggan perempuan yang profil perilaku belanjanya paling mendekati subscriber yang sudah ada. Dengan cara ini, alokasi anggaran kampanye dapat diarahkan secara lebih presisi ke pelanggan dengan probabilitas konversi tertinggi, bukan disebarkan secara merata ke seluruh segmen tanpa prioritas.

Rekomendasi 2: Strategi Diferensiasi High Spender dan Regular Spender

- ***Justifikasi Analitik***

  Segmentasi berbasis persentil ke-75 dari *Purchase Amount* ($81) menghasilkan dua kelompok yang berbeda secara mencolok: *High Spender* (rata-rata $90,55, n = 978) dan *Regular Spender* (rata-rata $49,46, n = 2.922). Perbedaan senilai ~$41 per transaksi ini terkonfirmasi secara statistik dengan kekuatan yang sangat besar (Mann-Whitney U, p < 0,0001, Cohen's d = 3,12). Yang membuat temuan ini semakin dapat diandalkan adalah hasil *robustness check* yang menunjukkan Cohen's d konsisten di rentang 2,85 hingga 3,45 pada berbagai *threshold* Q60 hingga Q85, sehingga kesimpulan tidak bergantung pada satu titik batas tertentu. Meskipun *High Spender* hanya 25,1% dari total pelanggan, nilai transaksi rata-rata mereka hampir dua kali lipat dari *Regular Spender*, menjadikan kelompok ini sebagai kontributor pendapatan yang tidak proporsional dan bernilai tinggi untuk dipertahankan.

- ***Langkah Implementasi***

  Perusahaan dapat menjalankan dua program secara paralel yang dirancang untuk tujuan yang berbeda. Untuk kelompok *High Spender*, dapat dikembangkan program *Premium Membership* dengan manfaat eksklusif seperti akses prioritas, layanan personal, atau keuntungan tambahan lainnya yang memperkuat loyalitas dan mempertahankan kontribusi

spending mereka. Untuk kelompok *Regular Spender*, dapat diperkenalkan program *spend-to-unlock* dengan sistem hadiah berjenjang yang secara bertahap mendorong peningkatan nilai transaksi hingga memenuhi syarat segmen premium. Kedua program ini dapat dikelola oleh tim *Customer Relationship Management* (CRM) dengan memanfaatkan model prediksi yang telah dibangun untuk mengidentifikasi pelanggan *Regular Spender* yang paling berpotensi untuk naik segmen.

b. Explain how these recommendations could support decision making for relevant stakeholders.

- **Rekomendasi 1: Peningkatan Jumlah Subscriber Melalui Kampanye Bertarget Berbasis Gender**

  Dukungan terhadap Pengambilan Keputusan Stakeholder

  Bagi tim marketing, rekomendasi ini menyediakan dasar segmentasi yang lebih tajam dibandingkan kampanye massal. Kombinasi antara data kesenjangan konversi gender dan feature importance model memberikan argumentasi yang terukur untuk mengalokasikan anggaran promosi secara lebih terarah, sekaligus memberikan arahan yang jelas mengenai insentif apa (diskon) dan kategori produk mana (Accessories dan Clothing) yang sebaiknya dijadikan fokus kampanye.

  Bagi manajemen keuangan, integrasi model prediksi ke dalam sistem CRM memungkinkan perencanaan anggaran yang lebih efisien karena target promosi dapat dipersempit ke pelanggan dengan probabilitas konversi tertinggi, sehingga biaya per akuisisi subscriber berpotensi lebih rendah dibandingkan pendekatan tanpa segmentasi.

  Bagi manajemen senior, fakta bahwa seluruh segmen perempuan (1.248 pelanggan) saat ini belum terkonversi menjadi subscriber merupakan sinyal strategis yang perlu mendapat perhatian dalam agenda pertumbuhan jangka panjang. Potensi peningkatan jumlah subscriber dari segmen ini sangat besar mengingat tidak diperlukan akuisisi pelanggan baru (target sudah tersedia dalam basis pelanggan yang ada).

- **Rekomendasi 2: Strategi Diferensiasi High Spender dan Regular Spender**

  Dukungan terhadap Pengambilan Keputusan Stakeholder

  Temuan segmentasi ini memberikan nilai praktis yang berbeda bagi setiap tingkatan pengambil keputusan. Bagi manajemen produk dan tim CRM, perbedaan rata-rata transaksi sebesar sekitar $41 antara kedua kelompok memberikan parameter konkret untuk merancang nilai insentif yang proporsional pada masing-masing program. Bagi tim keuangan, apabila 10% dari 2.922 pelanggan *Regular Spender* (±292 pelanggan) berhasil naik ke segmen *High Spender*, perusahaan berpotensi memperoleh tambahan pendapatan per periode berdasarkan selisih rata-rata nilai transaksi kedua segmen (~$41 per transaksi). Hal ini dapat dijadikan acuan awal dalam menilai kelayakan finansial program. Bagi manajemen senior, nilai $p < 0{,}0001$ dan Cohen's $d = 3{,}12$ yang konsisten pada berbagai *threshold* Q60 hingga Q85 menunjukkan bahwa pola segmentasi ini cukup stabil untuk dijadikan dasar pengambilan keputusan strategis. Untuk mengevaluasi efektivitas implementasi, perusahaan dapat memantau peningkatan *average purchase amount*, *customer retention rate*, serta proporsi pelanggan yang berhasil berpindah dari segmen *Regular Spender* ke *High Spender*.

c. Discuss potential risks or considerations if the recommendations are implemented.

- **Rekomendasi 1: Peningkatan Jumlah Subscriber Melalui Kampanye Bertarget Berbasis Gender**

  Risiko dan Mitigasi

  Risiko pertama berkaitan dengan efektivitas diskon sebagai instrumen konversi. Meskipun Discount Applied terbukti sebagai prediktor terkuat Subscription Status, temuan EDA sekaligus menunjukkan bahwa diskon tidak terbukti meningkatkan purchase amount secara berarti karena selisih rata-rata antara pelanggan yang mendapat diskon ($59,28) dan yang tidak ($60,13) kurang dari $1. Hal ini berarti program diskon yang dirancang untuk kampanye ini sebaiknya dievaluasi keberhasilannya menggunakan metrik konversi subscriber, bukan peningkatan nilai transaksi, agar ekspektasi terhadap program tidak meleset dari tujuan yang sebenarnya.

  Risiko kedua berkaitan dengan sifat hubungan yang ditemukan. Asosiasi antara gender dan Subscription Status yang teridentifikasi melalui uji Chi-Square bersifat statistik, bukan kausalitas artinya tidak dapat disimpulkan secara langsung bahwa gender adalah penyebab perbedaan konversi tersebut. Faktor-faktor lain yang tidak tercakup dalam dataset, seperti preferensi produk, paparan iklan, atau aksesibilitas program berlangganan, mungkin turut berperan. Oleh karena itu, kampanye berbasis segmentasi gender ini sebaiknya diuji terlebih dahulu melalui controlled experiment dalam skala terbatas sebelum diluncurkan secara penuh, guna memvalidasi apakah intervensi ini benar-benar menghasilkan peningkatan konversi yang signifikan. Selain itu, variabel kontekstual yang relevan tidak tercakup dalam dataset, sehingga validasi pada data aktual tetap diperlukan sebelum temuan ini dijadikan dasar kebijakan.

- **Rekomendasi 2: Strategi Diferensiasi High Spender dan Regular Spender**

  Risiko dan Mitigasi

  Risiko utama dari rekomendasi ini adalah potensi rasa ketidakadilan di kalangan *Regular Spender* apabila perbedaan manfaat antara kedua program terlalu mencolok, yang dapat memicu *churn* di segmen yang justru merupakan mayoritas pelanggan (74,9%). Untuk memitigasi hal ini, desain program perlu memastikan bahwa *Regular Spender* merasa dihargai dan memiliki jalur yang jelas untuk naik ke segmen premium, bukan merasa tersisihkan. Risiko kedua adalah keterbatasan dataset yang bersifat statis, dimana ambang batas $81 ditetapkan berdasarkan distribusi data historis tanpa dimensi waktu, sehingga nilai ini mungkin perlu dikalibrasi ulang apabila diterapkan pada data transaksi nyata yang lebih dinamis Terakhir, segmentasi ini berdasarkan satu variabel tunggal (*Purchase Amount*) dan belum mempertimbangkan frekuensi pembelian secara bersamaan, sehingga pelanggan dengan spending rendah namun frekuensi tinggi mungkin memiliki *lifetime value* yang sebanding dengan *High Spender* namun tidak teridentifikasi dalam segmentasi ini.